


Γενικές Οδηγίες για τις 2 μονάδες

Η άσκηση έχει ως βασικό στόχο να βρει συστάδες και ανωμαλίες σε **δισδιάστατα** σημεία χρησιμοποιώντας α) τον k-means ως αλγόριθμο στον οποίο θα βασιστεί ο εντοπισμός ανωμαλιών και β) LLMs ως βοηθητικό εργαλείο, του οποίου η εγκυρότητα πρέπει συνεχώς να ελέγχεται. Η άσκηση περιλαμβάνει τα εξής βήματα:

1. Λήψη συνόλων δεδομένων σε μορφή csv, γνωρίζοντας ότι υπάρχουν 5 συστάδες και κάποια outliers (ακρότατα). Τα παραδείγματα που δίνονται φαίνονται στις διπλανές εικόνες.
2. Καθαρισμός εγγραφών που είναι προβληματικές και ό,τι άλλο στάδιο προ-επεξεργασίας κρίνεται.
3. Εφαρμογή του k-means με στόχο να υπολογιστούν μετά πιο εύκολα τα outliers και όχι να πραγματοποιήσετε καλή συσταδοποίηση αυτή καθαυτή.
4. Εντοπισμός ανωμαλιών βάσει των αποτελεσμάτων του βήματος 3 με κλιμακώσιμο τρόπο.
5. Κριτική αξιολόγηση οδηγιών σε κάθε βήμα από chatGPT ή άλλο LLM της επιλογής σας.
6. Προσπαθήστε να ρωτήσετε απευθείας το LLM αν μπορεί να εντοπίσει ακρότατα. Τί αποτελέσματα βλέπετε και τί συμπεράσματα βγάζετε;
7. Προσπαθήστε να δημιουργήσετε δικά σας αντίστοιχα σύνολα δεδομένων με LLMs. Τί αποτελέσματα βλέπετε και τί συμπεράσματα βγάζετε;



Το πρόγραμμά σας πρέπει να είναι σε python ή java και να δέχεται ως μοναδική παράμετρο εισόδου το όνομα του αρχείου δεδομένων. Να υπολογίζετε/εκτυπώνετε σαφώς στην οθόνη τον χρόνο εκτέλεσης και τα αρχικά σημεία (δλδ. μη κανονικοποιημένα αν κάνετε κανονικοποίηση) που έχουν εντοπιστεί ως ακρότατα.

ΕΠΙΠΛΕΟΝ ΚΟΜΜΑΤΙ – BONUS: enhance an AI Data-mining agent!

Στο <https://github.com/Bilpapster/DaMi> θα βρείτε έτοιμο έναν σκελετό του agent που είδαμε ως demo στο μάθημα. Το UI και η σύνδεση με LLM δίνονται έτοιμα. Ο σκελετός περιλαμβάνει ένα tool `k_means_clustering()` με καλή περιγραφή για τον agent και ένα tool `dbscan_clustering()` που έχει poor documentation (και επομένως αναμένεται ο agent να μην μπορεί να το χρησιμοποιήσει σωστά). Ο στόχος είναι να φτιάξετε εσείς το documentation του DBScan και να προσθέσετε 2-3 επιπλέον tools που θα υλοποιούν άλλους αλγορίθμους clustering ή και την λύση σας στο κύριο μέρος της άσκησης.

Στο readme του παραπάνω συνδέσμου έχετε αναλυτικές οδηγίες πώς θα τρέχετε τον κώδικα, πώς προσθέτετε δεδομένα, πώς τον επεκτείνετε κλπ.

Παραδοτέα

A. Ένα συμπίεσμένο αρχείο με τον πηγαίο και οδηγίες χρήσης. Ο πηγαίος κώδικας να έχει εκτενή σχόλια είτε σε ελληνικά είτε στα αγγλικά και όχι σε greeklish. Οι οδηγίες χρήσης μπορούν να περιλαμβάνουν προαιρετικά και σύνδεσμο σε δικό σας github repository. Το όνομα του συμπίεσμένου αρχείου να είναι **AEM1_AEM2.zip**.

B. Μία τεχνική αναφορά σε μορφή παρουσίασης (σε pptx ή pdf) που να εξηγείτε την προσέγγισή σας (το πολύ 9 διαφάνειες συνολικά αν δεν ασχοληθήκατε με το επιπλέον κομμάτι, αλλιώς το πολύ 15 διαφάνειες).

Διευκρινήσεις

- Οι γραπτές εξετάσεις θα είναι με άριστα το 9. Όσοι δεν παραδώσουν/παρουσιάσουν την άσκηση μπορούν να λάβουν κανονικά μέρος στις εξετάσεις και να περάσουν το μάθημα, απλά θα έχουν μέγιστο βαθμό το 9.

- Για να προσμετρηθεί ο βαθμός της άσκησης, θα πρέπει ο βαθμός στις τελικές εξετάσεις να είναι τουλάχιστον 4 στα 9.
- Στη διάλεξη στις 8/1/2026 θα γίνει παρουσίαση της κάθε ομάδας καθώς η άσκηση θα εξεταστεί και προφορικά και όσοι την καταθέσουν είναι υποχρεωμένοι να παραστούν την ημερομηνία αυτή, αλλιώς θα ακυρωθεί η εργασία. Οι παρουσιάσεις θα πρέπει να διαρκούν 8'.
- Ο βαθμός της εργασίας θα ισχύει μέχρι να ξαναδιδαχθεί το μάθημα.